

# Fusão de evidência de bordas para canais de intensidade em imagens PolSAR

Anderson A. de Borba

Dept. Engenharia Elétrica e Computação  
UPM - Universidade Presbiteriana Mackenzie  
IBMEC-SP  
São Paulo, Brazil  
anderson.borba@ibmec.edu.br

Maurício Marengoni

Dept. Engenharia Elétrica e Computação  
UPM - Universidade Presbiteriana Mackenzie  
São Paulo, Brazil  
mauricio.marengoni@mackenzie.br

Alejandro C. Frery

Laboratório de Computação Científica e Análise Numérica - LACCAN  
UFAL - Universidade Federal de Alagoas  
Maceió, Brazil  
acfrery@gmail.com

**Abstract**—Atualmente, na área de sensoriamento remoto, pode-se encontrar diferentes métodos para detecção e fusão de evidências de bordas. Entretanto, alguns desses métodos, ao serem aplicados em imagens PolSAR, produzem resultados inadequados. Com intuito de melhorar sinal ruído, se tem investido em pesquisas com a utilização de modelagem estatística. O presente estudo, propõe um método de detecção e fusão de evidências de bordas baseado no método da máxima verossimilhança, utilizando fusão de informações por média, SWT, PCA, e estatística ROC. Os precedimentos foram aplicados para os canais de intensidade de uma imagem real PolSAR. Os resultados indicam um bom desempenho do método na detecção de bordas com possíveis caminhos para pesquisas futuras.

**Index Terms**—PolSAR, detecção de bordas, Estimativa de máxima verossimilhança, Métodos de Fusão.

## I. INTRODUCTION

Neste trabalho será apresentado uma pesquisa sobre detecção e fusão de evidências de bordas, em imagens de radar de abertura sintética (*Synthetic Aperture Radar* – SAR) e nas imagens de radar polarimétrico de abertura sintética (*Polarimetric Synthetic Aperture Radar* – PolSAR), ambas requerem modelos e algoritmos adequados para o tratamento das suas características especiais.

Podemos citar diferentes técnicas de detecção de bordas, como no trabalho de [1] onde é usado modelagem eletromagnética, ou os trabalhos de [2]–[5] os quais encontramos técnicas baseadas em métodos que estimam o gradiente. Assim como, no trabalho de [6], são utilizadas técnicas baseadas nas cadeias de Markov.

Em [7] é descrita a comparação entre vários detectores de bordas que seguem a ideia deste trabalho. Técnicas baseadas nas modelagens estatísticas têm sido usadas na detecção de bordas em imagens SAR, podemos citar os trabalhos de [7]–[10].

Atualmente as pesquisas em *Deep Learning* têm sido largamente usadas na área de sensoriamento remoto, podemos encontrar aplicações nas referências [11]–[14].

A área de fusão de imagens também é explorada neste trabalho. Um recente artigo, cujo autores são [15], usa ideias do método *random forest* aplicado em fusão de imagens PolSAR, adicionalmente, o artigo de [16] mostra outras técnicas de fusão de informação.

O presente trabalho seguirá a abordagem de modelagem estatística, principalmente as técnicas descritas em [9], [17] usando a distribuição Wishart. Para realizar a fusão de informações temos como base as referências [16], [18].

O objetivo deste trabalho é detectar bordas em cada canal de uma imagem PolSAR e realizar a fusão das evidências de bordas, com a tarefa de entender a importância da informação de cada um desses canais.

O artigo está estruturado da seguinte forma. A seção II é descrito a modelagem estatística para dados PolSAR, mostramos a modelagem usada nas seções III, IV e V. Na seção VI descrevemos os métodos de evidências de bordas com destaque ao método baseado em estatística ROC. Os resultados numéricos estão descritos na seção VII e finalmente na seção VIII serão apresentadas as conclusões do trabalho.

## II. MODELAGEM ESTATÍSTICA PARA DADOS POLSAR

Os sistemas SAR, totalmente polarimétricos, transmitem pulsos de micro-ondas polarizados ortogonalmente e medem componentes ortogonais do sinal recebido. Para cada pixel temos uma matriz de coeficientes de espalhamento, que são números complexos e descrevem a transformação do campo eletromagnético transmitido para o campo eletromagnético recebido.

A transformação pode ser representada como

$$\begin{bmatrix} E_h^r \\ E_v^r \end{bmatrix} = \frac{e^{ikr}}{r} \begin{bmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{bmatrix} \begin{bmatrix} E_h^t \\ E_v^t \end{bmatrix},$$

onde  $k$  denota o número de onda,  $\hat{i}$  é um número complexo e  $r$  é a distância entre o radar e o alvo. O campo eletromagnético com componentes  $E_i^j$  tem índice subscrito denotando a polarização horizontal ( $h$ ) ou vertical ( $v$ ), enquanto o índice sobrescrito indica a onda recebida ( $r$ ) ou transmitida ( $t$ ). Definindo  $S_{i,j}$  como os coeficientes de espalhamento complexo, tal que o índice  $i$  e  $j$  são associados com o recebimento e com a transmissão das ondas, por exemplo, o coeficiente de espalhamento  $S_{hv}$  está associado a onda transmitida na direção vertical ( $v$ ) e recebida na direção horizontal ( $h$ ).

Sendo conhecido cada coeficiente, a matriz de espalhamento complexa  $\mathbf{S}$  é definida por

$$\mathbf{S} = \begin{bmatrix} S_{hh} & S_{hv} \\ S_{vh} & S_{vv} \end{bmatrix}, \quad (1)$$

e se o meio de propagação das ondas é recíproco, então usaremos o teorema da reciprocidade [19] para definir a matriz de espalhamento como sendo hermitiana. Desta forma, a matriz de espalhamento pode ser representada pelo vetor

$$\mathbf{s} = \begin{bmatrix} S_{hh} \\ S_{hv} \\ S_{vh} \\ S_{vv} \end{bmatrix}. \quad (2)$$

E ainda, de acordo com as referências [20] e [21] podemos considerar a hipótese da distribuição ser circular gaussiana multivariada complexa de média zero  $N_3^C(0, \Sigma)$ , cuja função densidade de probabilidade (pdf) é:

$$f_{\mathbf{s}}(\mathbf{s}; \Sigma) = \frac{1}{\pi^3 |\Sigma|} \exp(-\mathbf{s}^H \Sigma^{-1} \mathbf{s}), \quad (3)$$

onde  $|\cdot|$  é a matriz determinante, o índice sobrescrito  $H$  denota o número complexo conjugado e  $\Sigma$  é a matriz de covariância da amostra  $\mathbf{s}$  tal que  $\Sigma = E(\mathbf{s}\mathbf{s}^H)$ .

Por consequência da distribuição ser circular gaussiana multivariada complexa com média zero, e as entradas do vetor  $\mathbf{s}$  são  $s_{ij} = R_{ij} + iI_{ij}$ , então por hipótese é exigido que  $R_{ij}$  e  $I_{ij}$  com  $j = h, v$  satisfaçam

- I-  $E[R_{ij}] = E[I_{ij}] = 0$ ,
- II-  $E[R_{ij}^2] = E[I_{ij}^2]$ ,
- II-  $E[R_{ij}I_{ij}] = 0$ ,
- IV-  $E[R_{ij}R_{ij}] = E[I_{ij}I_{ij}]$ ,
- V-  $E[I_{ij}R_{ij}] = -E[R_{ij}I_{ij}]$ .

onde,  $E[\cdot]$  denota o valor esperado.

A modelagem estatística descrita foi comprovada para dados SAR polarimétricos, confirmando-se que contém todas as informações necessárias para caracterizar o retroespalhamento, encontramos mais informações em [22] e [23].

A modelagem estatística descrita, até aqui, trata apenas a modelagem de visada simples, porém, imagens polarimétricas são usualmente sujeitadas a um processo de múltiplas visadas, com o intuito de melhorar a razão entre o sinal e o seu ruído. Para esse fim, matrizes positivas definidas hermitianas estimadas são obtidas computando a média de  $L$  visadas

independentes de uma mesma cena. Resultando na matriz de covariância amostral estimada  $\mathbf{Z}$  conforme [20], [24]

$$\mathbf{Z} = \frac{1}{L} \sum_{l=1}^L \mathbf{s}_l \mathbf{s}_l^H, \quad (4)$$

onde  $\mathbf{s}_l$  com  $l = 1, \dots, L$  amostras de  $L$  vetores complexos distribuídos como  $\mathbf{s}$ , assim a matriz de covariância amostral associada a  $\mathbf{s}_l$  denotam o espalhamento para cada visada  $L$ .

### III. FUNÇÃO DE DENSIDADE WISHART MÚLTIPLAS VISADAS

O processo de múltiplas visadas tem a função densidade de probabilidade (pdf) Wishart definida por,

$$f_{\mathbf{Z}}(\mathbf{Z}; \Sigma_{\mathbf{s}}, L) = \frac{L^m |\mathbf{Z}|^{L-m}}{|\Sigma_{\mathbf{s}}|^L \Gamma_m(L)} \exp(-L \text{tr}(\Sigma_{\mathbf{s}}^{-1} \mathbf{Z})), \quad (5)$$

onde,  $\text{tr}(\cdot)$  é o operador traço de uma matriz,  $\Gamma_m(L)$  é uma função Gamma multivariada definida por

$$\Gamma_m(L) = \pi^{\frac{1}{2}m(m-1)} \prod_{i=0}^{m-1} \Gamma(L-i)$$

e  $\Gamma(\cdot)$  é a função Gamma e  $m = 3$  para o presente artigo. Podemos afirmar que  $\mathbf{Z}$  é distribuído como uma distribuição Wishart denotando por  $\mathbf{Z} \sim W(\Sigma_{\mathbf{s}}, L)$  e satisfazendo  $E[\mathbf{Z}] = \Sigma_{\mathbf{s}}$ . Sem perda de generalidade para o texto, vamos usar o símbolo  $\Sigma$  em detrimento a  $\Sigma_{\mathbf{s}}$  para representar a matriz de covariância associada a  $\mathbf{S}$ .

### IV. DETECÇÃO DE BORDAS

Na literatura encontramos uma grande oferta de métodos clássicos para detectar bordas, por exemplo Sobel, Canny, Laplaciano da gaussiana(LoG) e LoG piramidal. Os métodos clássicos de detecção de bordas são construídos assumindo que o ruído é aditivo, o que torna esses métodos ineficientes para aplicação em imagens PolSAR.

Ao introduzir conceitos baseados nos artigos [8], [17] é possível propor um método de detecção de borda em imagens PolSAR com múltiplas visadas. A ideia principal é detectar o ponto de transição em uma faixa tão fina quanto possível entre duas regiões da imagem. O ponto de transição é definido como uma evidência de borda. Os ruídos nesse tipo de imagens são do tipo *speckle*, os mesmos têm natureza multiplicativa, tornando a detecção de bordas em imagens SAR uma tarefa desafiadora.

As metodologias de detecção de bordas ocorrem em diversos estágios, abaixo enumeramos os estágios:

- 1) identificar o centroide de uma região de interesse (ROI) de maneira automática, semiautomática ou manual;
- 2) construir raios do centroide para fora da área de interesse;
- 3) coletar dados em uma vizinhança em torno dos raios usando o algoritmo *Bresenham's midpoint line algorithm*, idealmente do tamanho de um pixel;
- 4) detectar pontos na faixa de dados, os quais fornecem evidências de mudanças de propriedades estatísticas, ou

seja, um ponto de transição que define uma evidência de borda;

- 5) usar o método Simulated Annealing Generalizado (GenSA), referência [25], para encontrar pontos de máximo em funções de interesse;
- 6) fusão de evidências de bordas detectadas nos canais  $(hh)$ ,  $(hv)$  e  $(vv)$ .

## V. MÉTODO DA MÁXIMA VEROSSIMILHANÇA

A estimativa por máxima verossimilhança (MLE) é um método que, tendo um conjunto de dados e um modelo estatístico, estima os valores dos parâmetros do modelo maximizando uma função de probabilidade dos dados. O conceito de verossimilhança pode ser encontrado nos artigos [8], [17].

Suponha  $\mathbf{X} = (X_1, X_2, \dots, X_n)^T$  um vetor randômico distribuído de acordo com a função densidade de probabilidade (pdf)  $f(\mathbf{x}, \theta)$  com parâmetros  $\theta = (\theta_1, \dots, \theta_d)^T$  no espaço dos parâmetros  $\Theta$ . Definimos a função de verossimilhança

$$L(\theta; \mathbf{X}) = \prod_{i=1}^n f(x_i; \theta),$$

e a função logarítmica de verossimilhança a qual podemos chamar de função de log-verossimilhança

$$l(\theta; \mathbf{X}) = \ln(L(\theta; \mathbf{X})) = \sum_{i=1}^n \ln(f(x_i; \theta)). \quad (6)$$

De maneira simplificada a estimativa de máxima verossimilhança pode ser escrita por

$$\hat{\theta} = \arg \max_{\theta \in \Theta} L(\theta; \mathbf{x}),$$

e de maneira similar

$$\hat{\theta} = \arg \max_{\theta \in \Theta} l(\theta; \mathbf{x}).$$

Vamos usar o método de máxima verossimilhança aplicado na distribuição Wishart. Suponha  $\mathbf{Z} = (\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_N)^T$  um vetor randômico distribuído de acordo com a função densidade de probabilidade (pdf) (5) com parâmetros  $\Sigma = \{\Sigma_A, \Sigma_B\}$  e  $L$ . Os parâmetros  $\Sigma_A$ ,  $\Sigma_B$  pertencem a duas amostras diferentes  $A$  e  $B$ , nosso objetivo é detectar a fronteira entre as duas amostras.

A função de verossimilhança da amostra descrita por (6) é dada pela equação do produto das funções de densidade, respectivamente associadas a cada amostra

$$L(j) = \prod_{k=1}^j f_{\mathbf{Z}}(\mathbf{Z}'_k; \Sigma_A, L) \prod_{k=j+1}^N f_{\mathbf{Z}}(\mathbf{Z}'_k; \Sigma_B, L), \quad (7)$$

onde  $\mathbf{Z}'_k$  é uma possível aproximação da matriz randômica descrita em (4).

Usando a equação (6), teremos a função de log-verossimilhança

$$l(j) = \ln L(j) = \sum_{k=1}^j \ln f_{\mathbf{Z}}(\mathbf{Z}'_k; \Sigma_A, L) + \sum_{k=j+1}^N \ln f_{\mathbf{Z}}(\mathbf{Z}'_k; \Sigma_B, L). \quad (8)$$

Nesse momento, podemos realizar manipulações algébricas na função densidade de probabilidade em cada termo do somatório e substituir nas duas parcelas da equação (6) resultando em

$$\begin{aligned} l(j) &= N [mL \ln(L) - \ln(\Gamma_m(L))] \\ &- L [j \ln(|\Sigma_A|) + (N-j) \ln(|\Sigma_B|)] \\ &+ (L-m) \sum_{k=1}^N \ln(|\mathbf{Z}'_k|) \\ &- L \left[ \sum_{k=1}^j \text{tr}(\Sigma_A^{-1} \mathbf{Z}'_k) + \sum_{k=j+1}^N \text{tr}(\Sigma_B^{-1} \mathbf{Z}'_k) \right]. \end{aligned} \quad (9)$$

A matriz  $\Sigma$  pode ser encontrada usando o estimador de máxima verossimilhança denotado por  $\hat{\Sigma}$  de acordo com a referência [20]. A equação (10) representa duas estimativas para a matriz de covariância  $\Sigma$  que dependem da posição  $j$

$$\hat{\Sigma}_I(j) = \begin{cases} j^{-1} \sum_{k=1}^j \mathbf{Z}_k & \text{se } I = A, \\ (N-j)^{-1} \sum_{k=j+1}^N \mathbf{Z}_k & \text{se } I = B. \end{cases} \quad (10)$$

Na equação (9) podemos substituir a equação (10) e continuar a manipulação algébrica, tendo como resultado

$$\begin{aligned} l(j) &= N [-mL(1 - \ln(L)) - \ln(\Gamma_m(L))] \\ &- L \left[ j \ln(|\hat{\Sigma}_A(j)|) + (N-j) \ln(|\hat{\Sigma}_B(j)|) \right] \\ &+ (L-m) \sum_{k=1}^N \ln(|\mathbf{Z}'_k|). \end{aligned} \quad (11)$$

O argumento máximo  $\hat{j}_{ML}$  é uma evidência de borda que será usada nos métodos de fusão.

$$\hat{j}_{ML} = \arg \max_j l(j).$$

## VI. MÉTODOS DE FUSÃO DE EVIDÊNCIAS DE BORDAS

### A. Média simples

O método de fusão com média simples propõe a média aritmética das evidências de bordas, em cada canal. A fusão das evidências de bordas pode ser calculada por

$$IF(x, y) = \frac{1}{nc} \sum_{i=1}^{nc} IE_i(x, y), \quad (12)$$

onde  $nc$  é o número de canais a serem utilizados na fusão. Podemos obter mais detalhes na referência [18].

### B. Transformada wavelet estacionária - SWT

Esta seção, novamente é baseada na referência [26]. O método de fusão SWT pode ser descrito pelos seguintes passos:

- calcule a decomposição SWT obtendo  $L_{HH}$ ,  $L_{HL}$ ,  $L_{LH}$  e  $L_{LL}$  para cada canal;
- nas decomposições  $L_{HH}$  é realizada a média aritmética de todos canais, pixel a pixel, e nas decomposições  $L_{HL}$ ,  $L_{LH}$  e  $L_{LL}$ , é encontrado o máximo entre cada canal, pixel a pixel, restando uma nova decomposição  $\bar{L}_{HH}$ ,  $\bar{L}_{HL}$ ,  $\bar{L}_{LH}$  e  $\bar{L}_{LL}$ ;
- realizando a transformação inversa de SWT, obtemos a imagem com a fusão das evidências de bordas  $IF(x, y)$ .

### C. Principal component analysis - (PCA)

Esta seção é baseada na referência [26] e [18]. O método de fusão baseado no PCA pode ser descrito pelos seguintes passos:

- organizar os dados de forma a ter cada imagem em um vetor coluna, formando uma matriz  $Y$  de dimensão  $l \times nc$ , onde  $l = m \cdot n$ , representa a multiplicação das  $m$  linhas e  $n$  colunas das matrizes a serem utilizadas na fusão;
- calcule a média dos elementos dessas colunas, gerando um vetor de dimensão  $1 \times nc$ ;
- subtraia a média de cada coluna da matriz  $Y$ . Resultando em uma matriz  $X$  de mesma dimensão de  $Y$ ;
- ache a matriz de covariância  $C$  proveniente de  $X$ , calculando  $C = XX^T$ ;
- calcule os autovalores  $\Lambda$  e os autovetores  $D$ , e ordene os autovalores e autovetores em ordem decrescente. As matrizes geradas pelos autovalores, na diagonal principal, e os autovetores colocados em coluna, têm dimensões  $nc \times nc$ ;
- compute as componentes  $P_i = \frac{V_i}{\sum_{i=1}^{nc} V_i}$  com  $i = 1, \dots, nc$ ;
- realizamos a fusão  $IF(x, y) = \sum_{i=1}^{nc} P_i IE_i(x, y)$ . Lembrando que o  $\sum_{i=1}^{nc} P_i = 1$ .

### D. Estatística ROC

O método Estatística ROC foi proposto e descrito em detalhes nas referências [27] e [28]. O método descreve um modelo estatístico para obter informações de maneira automática, de diversas imagens, ou, em diversos canais. Podemos descrever o método no seguinte procedimento:

- obter as evidências de bordas nos canais, aplicando o método descrito nesse artigo. Armazene essas evidências de bordas em matrizes  $E_i$ , com  $i = 1, \dots, nc$  de maneira binária;
- defina uma matriz de frequência de bordas  $V$ . A matriz  $V$  é gerada, somando as evidências de bordas  $E_i$ ;
- utilize limiares variando de  $t = 1, \dots, nc$  gerando matrizes  $M_t$ ;
- faça a comparação de cada  $M_t$ , fixada com todas as  $E_i$ , encontre a matriz de confusão para gerar a curva ROC. O ponto da curva ROC que se aproximar (no sentido da distância euclidiana) da linha diagnóstico, terá seu limiar considerado ótimo;
- a matriz  $M_t$ , que corresponde ao limiar mais próximo da linha diagnóstico, é a fusão de evidências de bordas.

## VII. RESULTADOS NUMÉRICOS

A imagem PolSAR, com 4 visadas da região de Flevoland na Holanda, foi usada para os testes numéricos. A figura (1) mostra a região de interesse, onde construímos as retas radiais para a detecção de bordas.

A detecção de bordas e suas posteriores fusão de evidências foram realizadas nessa região de interesse, com intuito de entender a ponderação de cada canal, na formação da imagem.

Neste trabalho a detecção de bordas foi realizada nos canais de intensidade (hh), (hv) e (vv), e posteriormente, usadas para a fusão de informações.




Fig. 1. Região de interesse (ROI) na imagem de Flavoland.

As figuras (2), (3) e (4) mostram, respectivamente, os algoritmos de detecção das evidências de bordas, aplicados nos canais (hh), (hv) e (vv).

O algoritmo para detectar as evidências de bordas funcionou bem nos canais (hh) e (hv), atingindo uma melhor acurácia em relação ao canal (vv).

No canal (vv) foi detectado bordas que não fazem parte da região homogênea de interesse, porém, fazem parte de outras bordas da imagem, pesquisando o motivo desse fato, foi analisado a função  $l(j)$  e constatado que a função apresenta dois picos, representando possíveis evidências de bordas, no qual o maior foi detectado corretamente.

As figuras (5) até (8) mostram, respectivamente, a fusão de evidências para os métodos descritos neste artigo. Em ordem, listamos o método que mostra a média de evidências de bordas, o método que usa a Stationary wavelet transform (SWT), o método que usa a Principal component analysis (PCA) e finalmente, o método baseado na estatística ROC.

Os métodos mostrados nas figuras (5), (6) e (7) usam todos os pixels detectados nos diferentes canais. Cada método pondera os pixels nos diferentes canais com suas características. A média pondera, igualmente, os pixels. O (SWT) encontra os coeficientes da combinação linear das suas bases de wavelets, e o (PCA) pondera os autovetores da matriz de covariância.

O método da estatística ROC não usa todos os pixels dos canais, pois o método é baseado em limiares descartando pixels. Isso se observou na figura (8).

## VIII. CONCLUSÃO

Nesse estudo, a abordagem de modelagem estatística foi aplicada em imagem de dados PolSAR real. Buscando-se entender a importância da informação de cada um desses




Fig. 2. Evidências de bordas detectadas no canal (hh).




Fig. 3. Evidências de bordas detectadas no canal (hv).

canais na fusão de evidências de bordas. Foi aplicado o algoritmo proposto em três canais de intensidade (hh), (hv) e (vv). Inicialmente, encontramos as evidências de bordas, usando o método da máxima verosimilhança em cada um dos canais, obtendo-se bons resultados. Ao analisar os resultados obtidos nos três canais, observou-se que o método para a detecção de bordas funcionou bem nos canais (hh) e (hv) atingindo melhor acurácia em relação ao canal (vv).

Posteriormente, foi realizado a fusão de evidências de bordas com os métodos de média simples, SWT, PCA e estatística ROC. Os três primeiros métodos tiveram bom desempenho como mostram os resultados. O método de estatística ROC suprimiu vários pontos de bordas, comportamento esperado por ser um método que usa limiares, entretanto, ao ser aplicado em maior número de canais, seu desempenho tende a melhorar.

Com base nesses resultados um possível caminho para

melhorá-los seria aumentar o número de canais estudados. Abrindo espaço para futuras pesquisa aplicando-se outros métodos de fusão de evidências de bordas.

## REFERENCES

- [1] S. J. S. Sant'Anna, J. C. Da S. Lacava, and D. Fernandes, "From maxwell's equations to polarimetric sar images: A simulation approach," *Sensors*, vol. 8, no. 11, pp. 7380–7409, 2008. [Online]. Available: <http://www.mdpi.com/1424-8220/8/11/7380>
- [2] R. Touzi, A. Lopes, and P. Bousquet, "A statistical and geometrical edge detector for sar images," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 26, no. 6, pp. 764–773, Nov 1988.
- [3] C. J. Oliver, D. Blacknell, and R. G. White, "Optimum edge detection in sar," *IEE Proceedings - Radar, Sonar and Navigation*, vol. 143, no. 1, pp. 31–40, Feb 1996.
- [4] R. Fjortoft, A. Lopes, P. Marthon, and E. Cubero-Castan, "An optimal multiedge detector for sar image segmentation," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 36, no. 3, pp. 793–802, May 1998.




Fig. 4. Evidências de bordas detectadas no canal (vv).




Fig. 5. Fusão de evidências de bordas usando o método da média.

- [5] X. Fu, H. You, and K. Fu, "A statistical approach to detect edges in sar images based on square successive difference of averages," *IEEE Geoscience and Remote Sensing Letters*, vol. 9, no. 6, pp. 1094–1098, Nov 2012.
- [6] F. Baselice and G. Ferraioli, "Statistical edge detection in urban areas exploiting sar complex data," *IEEE Geoscience and Remote Sensing Letters*, vol. 9, no. 2, pp. 185–189, March 2012.
- [7] E. Girón, A. C. Frery, and F. Cribari-Neto, "Nonparametric edge detection in speckled imagery," *Mathematics and Computers in Simulation*, vol. 82, no. 11, pp. 2182 – 2198, 2012. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S037847541200136X>
- [8] J. Gambini, M. Mejail, J. Jacobo-Berlles, and A. C. Frery, "Feature extraction in speckled imagery using dynamic B-spline deformable contours under the G0 model," *International Journal of Remote Sensing*, vol. 27, no. 22, pp. 5037–5059, 2006.
- [9] A. C. Frery, J. Jacobo-Berlles, J. Gambini, and M. Mejail, "Polarimetric SAR image segmentation with b-splines and a new statistical model," *CoRR*, vol. abs/1207.3944, 2012.
- [10] M. Horritt, "A statistical active contour model for sar image segmentation," *Image and Vision Computing*, vol. 17, no. 3, pp. 213 – 224, 1999. [Online]. Available: <http://www.sciencedirect.com/science/article/pii/S0262885698001012>
- [11] J. E. Ball, D. T. Anderson, and C. S. Chan, "A comprehensive survey of deep learning in remote sensing: Theories, tools and challenges for the community," *CoRR*, vol. abs/1709.00308, 2017. [Online]. Available: <http://arxiv.org/abs/1709.00308>
- [12] X. X. Zhu, D. Tuia, L. Mou, G. Xia, L. Zhang, F. Xu, and F. Fraundorfer, "Deep learning in remote sensing: A comprehensive review and list of resources," *IEEE Geoscience and Remote Sensing Magazine*, vol. 5, no. 4, pp. 8–36, Dec 2017.
- [13] J. Pont-Tuset, P. Arbeláez, J. T. Barron, F. Marques, and J. Malik, "Multiscale combinatorial grouping for image segmentation and object proposal generation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 39, no. 1, pp. 128–140, Jan 2017.
- [14] S. Xie and Z. Tu, "Holistically-nested edge detection," *Int. J. Comput. Vision*, vol. 125, no. 1-3, pp. 3–18, Dec. 2017. [Online]. Available: <https://doi.org/10.1007/s11263-017-1004-z>
- [15] A. Samat, P. Gamba, S. Liu, Z. Miao, E. Li, and J. Abuduwaili, "Quad-polsar data classification using modified random forest algorithms to map halophytic plants in arid areas," *Int. J. Applied Earth Observation and Geoinformation*, vol. 73, pp. 503–521, 2018. [Online]. Available: <https://doi.org/10.1016/j.jag.2018.06.006>
- [16] A. Salentini and P. Gamba, "A general framework for urban area extraction exploiting multiresolution sar data fusion," *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 9, no. 5, pp. 2009–2018, May 2016.




Fig. 6. Fusão de evidências de bordas usando o método swt.




Fig. 7. Fusão de evidências de bordas usando o método pca.

- [17] A. Nascimento, M. Horta, A. Frery, and R. Cintra, "Comparing edge detection methods based on stochastic entropies and distances for polar imagery," *Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, vol. 7, no. 2, pp. 648–663, 2014.
- [18] H. Mitchell, *Image Fusion: Theories, Techniques and Applications*. Springer Berlin Heidelberg, 2010. [Online]. Available: <https://books.google.com.br/books?id=D7DXAX6eH2oC>
- [19] J.-S. Lee and E. Pottier, *Polarimetric radar imaging: from basics to applications*. CRC press, 2009.
- [20] N. R. Goodman, "The distribution of the determinant of a complex wishart distributed matrix," *Ann. Math. Statist.*, vol. 34, no. 1, pp. 178–180, 03 1963. [Online]. Available: <http://dx.doi.org/10.1214/aoms/1177704251>
- [21] J. S. Lee, K. W. Hoppel, S. A. Mango, and A. R. Miller, "Intensity and phase statistics of multilook polarimetric and interferometric SAR imagery," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 32, no. 5, pp. 1017–1028, Sep. 1994.
- [22] K. Sarabandi, "Derivation of phase statistics from the mueller matrix," *Radio Science*, vol. 27, 11 1992.
- [23] C. López-Martínez, X. Fàbregas, and E. Pottier, "Multidimensional speckle noise model," *EURASIP Journal on Advances in Signal Processing*, vol. 2005, no. 20, p. 180956, Dec 2005. [Online]. Available: <https://doi.org/10.1155/ASP.2005.3259>
- [24] S. N. Anfinsen, A. P. Doulgeris, and T. Eltoft, "Estimation of the equivalent number of looks in polarimetric synthetic aperture radar imagery," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 47, no. 11, pp. 3795–3809, 2009.
- [25] Yang Xiang, S. Gubian, B. Suomela, and J. Hoeng, "Generalized simulated annealing for efficient global optimization: the GenSA package for R," *The R Journal Volume 5/1, June 2013*, 2013. [Online]. Available: <https://journal.r-project.org/archive/2013/RJ-2013-002/index.html>
- [26] V. Naidu and J. Raol, "Pixel-level image fusion using wavelets and principal component analysis," *Defence Science Journal*, vol. 58, no. 3, pp. 338–352, Mar. 2008. [Online]. Available: <https://publications.drdo.gov.in/ojs/index.php/dsj/article/view/1653>
- [27] S. Giannarou and T. Stathaki, "Optimal edge detection using multiple operators for image understanding," *EURASIP Journal on Advances in Signal Processing*, vol. 2011, no. 1, p. 28, Jul 2011. [Online]. Available: <https://doi.org/10.1186/1687-6180-2011-28>
- [28] T. Fawcett, "An introduction to roc analysis," *Pattern Recogn. Lett.*, vol. 27, no. 8, pp. 861–874, Jun. 2006. [Online]. Available: <http://dx.doi.org/10.1016/j.patrec.2005.10.010>




Fig. 8. Fusão de evidências de bordas usando o método ROC.